



פרויקט סקרנות - חלק ג' - פירמול הבעיה שלנו כבעיית סקרנות

רקע ותזכורת

בהמשך למה שכתבנו בחלק א' ובחלק ב', נתונים לנו רשומות משחקים מ-6 ליגות באירופה (ליגה ספרדית, ליגה אנגלית, ליגה איטלקית, ליגה צרפתית, ליגה גרמנית והליגה הרוסית) בין השנים 2014 ל-2020.

מה שאנו רוצים ללמוד הוא האם קבוצה, במשחק מסוים, תנצח, תסיים בתיקו או תפסיד. הפלט מהרשת יהיה ההסתברות לכל אחת מהאפשרויות כאשר ניקח את האפשרות עם ההסתברות הגבוהה ביותר כחיזוי שלנו. לדוגמא, עבור רקורד ספציפי של נתונים הרשת תפלוט שההסתברויות לניצחון, תיקו והפסד הן 50%, 35% ו-15% בהתאמה אז החיזוי שלנו הוא ניצחון.

את הדאטה שלנו חילקנו באופן הבא: 20% ישמש לטסט, 80% לסט האימון. נירמלנו את כל הפיצ'רים לטווח ערכים בין 0 ל-1, הסיבה שעשינו זאת היא כדי שהמשקלים שיש בניורונים יהיו פחות או יותר באותו סדר גודל, אם לפיצ'ר מסוים טווח הערכים הוא באלפים ולפיצ'ר אחר הוא במספרים עשרוניים קטנים אז המשקלים יהיו בסקלות שונות ואת זה רצינו למנוע. את תיאור הפיצ'רים השונים תיארנו בתחילת הדו"ח של חלק ב' (תזכורת - בנספחים)

1. א. הגדרת הפעולות האפשריות:

כדי להגדיר את הפעולות האפשריות מכל מצב במרחב המצבים האפשריים, עלינו ראשית להגדיר מהו מצב ומהו מרחב המצבים האפשרי:

State – המצב בו אנו נמצאים הוא המצב **אחרי** בחירת פיצ'ר מסוים (חוץ ממצב s_0 - המצב הראשוני בו טרם נבחר איזשהו פיצ'ר). כלומר בכל מצב, המודל הלומד שלנו (Learner) בוחן דאטה המכיל מס' פיצ'רים שונים. המעבר למצב הבא יהיה בבחירת פיצ'ר נוסף מתוך רשימת הפיצ'רים שלא נבחרו עדיין. כלומר, בחירת הפיצ'ר הבא מסט הפיצ'רים הינה האקשן אותה ה-Actor מבצע ואותה פעולה מובילה אותנו למצב הבא- זה שמוגדר לאחר ביצועה שהוא בחירת אותו הפיצ'ר. פורמלית: המצב הבא = הפיצ'ר הבא שנבחר. מרחב המצבים האפשרי על בסיס הדאטה שלנו (סה"כ 14 מצבים, 13 פיצ'רים ועוד מצב s_0):

$s \in S: \{s_0, xG, xGA, npxG, npxGA, npxGD, ppda_att, ppda_def, oppda_att, oppda_def, ppda_coef, oppda_coef, deep, deep_allowed\}$

Action - מכיוון שאנו עובדים עם Dataset טבלאי, כפי שלמדנו בהרצאה נתייחס ל-Agent כאותו DataScientist ול-Actions אותן יוכל לבצע כפעולות על ה-Data עצמו. לכן, נגדיר את סט הפעולות כפעולות האפשריות בתהליך ה-Curious Feature Selection. אקשן אפשרי מכל סטייט (ממרחב



המצבים שהוגדר לעיל) יהיה לבחור את אחד מהפיצ'רים שטרם נבחרו ולהוסיף אותו לדאטה אותה ה-Learner לומד. מכל מצב S , הפעולות האפשריות לביצוע ע"י המודל יהיו בחירת פיצ'ר 1 מהקבוצה הבאה:

$A \in a : \{ \text{List of Features} \cap \text{List of Yet Selected Features} \}$

Learner - במקרה שלנו מדובר במודל רשת ה-NN שבנינו בחלק ב': ברשת ANN מסוג sequential בעלת שתי שכבות, 13 נירונים בכל Hidden Layer, פונקציית אקטיבציה מסוג relu ואופטימיזר RMSprop, בחרנו בפרמטרים אלו לרשת על פי ניתוח הרגשיות שביצענו בחלק ב' בפרויקט.

ב. הגדרת התגמול

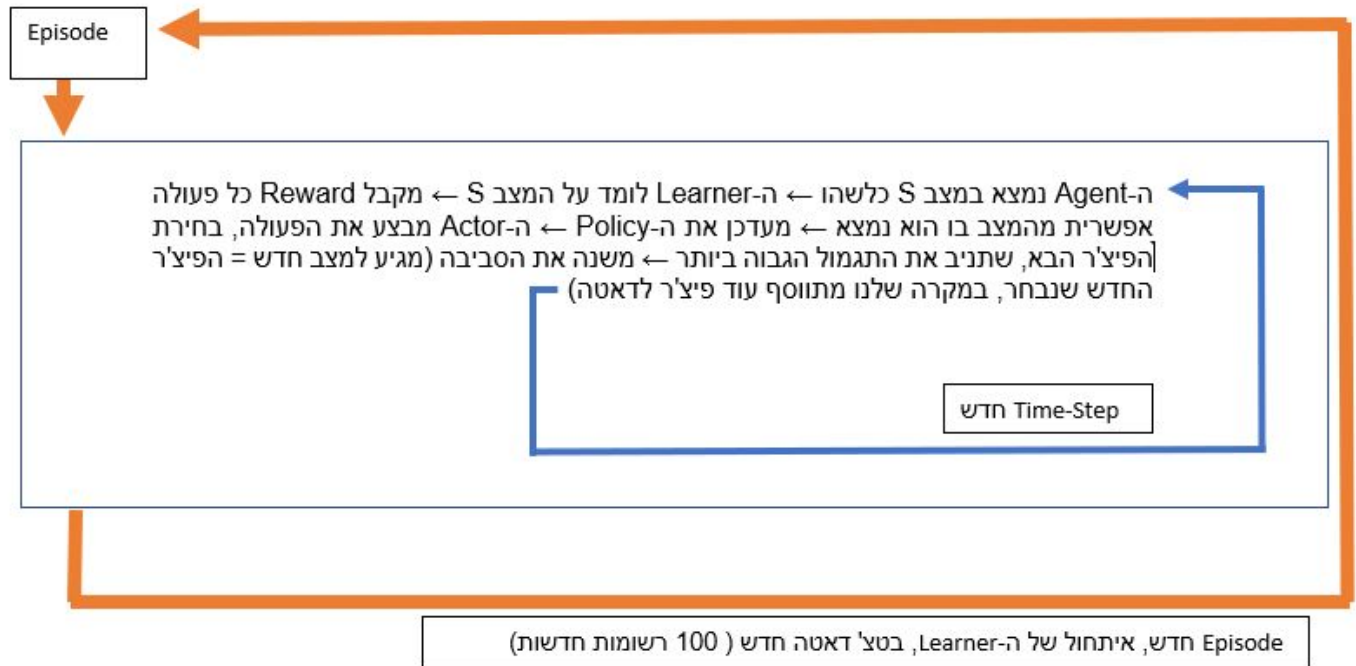
תגמול - התגמול כפי שהוגדר על ידינו הינו **ההפרש** בין השגיאה החדשה של המודל שנקבל לבין השגיאה הקודמת בעבור אותו המודל (ובאותו ה-Episode) שקיבלנו בכל מעבר ממצב למצב אחר באמצעות בחירה בפעולה מסויימת (כלומר, בחירת פיצ'ר שיתווסף לדאטה מתוך סט הפיצ'רים שטרם נבחרו). חישוב השגיאה נעשה באמצעות פונקציה נוספת ("get_error") המחשבת את השגיאה (MSE) (של המודל לעומת ה-**Validation dataset** בהינתן הפיצ'ר שהתווסף במעבר למצב הבא.

חשוב לציין כי בריצה הראשונה בתוך האפיזודה מוגדרת השגיאה הקודמת כ-0.5 ובכל סיום Time-step פנימית נגדיר את השגיאה החדשה שהתקבלה כ"שגיאה הקודמת" ל Time-step הבאה בתוך אותה האפיזודה. כך, בתחילתה של כל אפיזודה נאתחל את ערך השגיאה ל-0.5 ו-learner חדש (מאותחל) ילמד על סמך הפוליסי הקיים כעת בטבלת ה-Q.



ג. סגירת "לולאת סקרנות"

לולאת הסקרנות- לולאת הסקרנות שהוגדרה כדלהלן:



פירוט:

הכנות לפני הרצת לולאת הסקרנות:

נחלק את הדאטה שלנו ל-Batches. מכיוון שהדאטה שלנו מכיל 24,580 רשומות ובהגדירנו את מספר ה-training set להיות 80% מסך כל הדאטה הרשומות כך שבכל אפיזודה יבחרו 100 רשומות מסך כל הרשומות ב-train set, ה-Learner יתאמן על 80 רשומות ו-20 רשומות יהיו וולידציה לאותה אפיזודה, סה"כ הלולאה כוללת ריצה על 19,664 שורות \Leftarrow 1,966 איטרציות (אפיזודות)

טרם האפיזודה הראשונה (בלבד), הפוליסי הראשונית שלנו (טבלת ה-Q הראשונית) תהא מאותחלת, כלומר כל אחד מהערכים ב-Q table מאותחל לערך "1.0". טבלת ערכי ה-Q הינה טבלה בגודל 14×14 ($n=14 \Rightarrow |F|=14$, אחד יותר ממס' הפיצ'רים בגלל מצב So - הקבוצה הריקה).

פרמטר "גאמא" (Discount Factor) - קובע מהי חשיבות ה-future reward. ייקבע לערך 0.9.



כניסה ל-Episode חדש וריצת Episode:

א. בכל Episode נאפס את המידע שיש למודל הלומד שלנו לגבי העולם אותו הוא חוקר. כלומר, הטעות הקודמת תאותחל לערך "0.5", ה-Learner יחל ללמוד ממצב "So" המעבר למצב הבא יהיה ע"י ביצוע אחת מן הפעולות האפשריות ע"י ה-Actor.

לדוגמא, בהינתן שמדובר במעבר ממצב So למצב הבא - פעולה אפשרית תהיה בחירת כל פיצ'ר מסט הפיצ'רים (13 במספר) בדאטה.

בנוסף, נאתחל את רשת שלנו מכל המידע שהיא למדה על ידי הפקודה:

```
keras.backend.clear_session()
```

אופן בחירת הפעולה הרצויה תבוצע כאחת משתי אפשרויות:

1. בחירת פיצ'ר שטרם נבחר בצורה רנדומלית (Exploration)
2. בחירת פיצ'ר שטרם נבחר על סמך פוליסי קיים (הערכים בטבלת ה-Q, שיטת Exploitation)

הבחירה בין Exploration ל-Exploitation נעשית ע"י שימוש באלגוריתם Epsilon-greedy. כלומר ע"י הגרלת מספר פסאודו-רנדומלי בין 0 ל-1 והשוואתו לערך הנוכחי של הפרמטר "אפסילון" ϵ . ערכו של אפסילון נקבע באמצעות Scheduling בו הוא משתנה כתלות באפיזודה הכוללת בה אנו נמצאים בסה"כ. (ולא כתלות ב-Time_step בתוך כל אחד מהאפיזודות). ככל שנעלה במספר האיטרציות הכולל כך ההסתברות שנבצע Exploration, כלומר בחירת פעולה אקראית ולא לפי מדיניות, תקטן.

```
1 # epsilon is the tuner between exploration and exploitation
2 def get_epsilon(index_, itr_):
3     epsilon_ = 0.9
4     if index_ < itr_/4: epsilon_ = 0.9
5     elif itr_/4 <= index_ < itr_/2: epsilon_ = 0.5
6     elif itr_/2 <= index_ < itr_*0.75: epsilon_ = 0.3
7     else: epsilon_ = 0.1
8     return epsilon_
```

ערכיו השונים של אפסילון נקבעו על ידינו לאחר ביצוע רנדום סרצ' על פני מספר אפשרויות שונות. בסופו של דבר, הוחלט שנשתמש בערכים כפי שהוסברו בהרצאה (על סמך המאמר) מכיוון שהם נתנו את התוצאות הטובות ביותר על הדאטה שלנו.



הדבר נכון גם לגבי מקדם הלמידה (Learning rate), אלפא, אותו נשנה כתלות בהתקדמות במספר האיטרציות הכולל (סה"כ לכל האפיזודות). בהתחלה נרצה ללמוד יותר, כלומר משקל גדול יותר למידע חדש ואחר כך נבצע "fine-tuning" באמצעות משקל קטן יותר ללמידה:

```
1 # alpha is the Learning rate
2 def get_alpha(index_, itr_):
3     alpha_ = 0.09
4     if index_ < itr_/4: alpha_ = 0.09
5     elif itr_/4 <= index_ < itr_/2: alpha_ = 0.05
6     elif itr_/2 <= index_ < itr_*0.75: alpha_ = 0.01
7     else: alpha_ = 0.005
8     return alpha_
```

בסופו של דבר, לאחר קריאת ספרות בנושא, הוחלט שנשתמש בערכים כפי שניתנו במאמר שהוצג בכיתה, מכיוון שהם נתנו את התוצאות הטובות ביותר על הדאטה שלנו.

יש לציין כי תהליך הרנדום סרצ' בשני המקרים הושמט מהקוד במכוון, וזאת משום ומצאנו שזמן ההרצה יחד עם הרדום סרצ' הינו ארוך מדי (למעלה מ-24 שעות ריצה).

עדכון טבלת ה-Q

בעדכון הראשון אנו לא מעדכנים לפי משוואת בלמן כמו בשאר העדכונים שיתוארו בהמשך אלא השמה ישירה של הריוורד.

בכל אפיזודה, בסיומו של כל Time-Step, נעדכן את הערך המתאים לפעולה בטבלת ערכי ה-Q.

על פי המידע החדש שקיבלנו ובשימוש במשוואת בלמן וערך הפרמטרים:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

כאשר :

a- פעולה עתידית אפשרית

r- התגמול כפי שהוגדר לעיל

אלפא- מקדם הלמידה כפי שהוגדר



גאמא - Discount Factor - בעל ערך קבוע במודל שלנו- 0.9. מספר זה נבחר משום שכפי שנאמר בהרצאה, זהו מספר שבחזקה קטן בצורה יפה- לא קרוב מדי ל"1" ובנוסף לא מתקרב ל"0" מהר מדי, לא הופך את המכפלה שלו לא רלוונטית תוך מספר נמוך יחסית של איטרציות.

חשוב לציין כי בהינתן כי הערך בתא הטבלה התואם ל- $Q(s,a)$ הינו הערך ההתחלתי ("1.0") שכל תא יכול לקבל, נעדכן אותו לא לפי משוואת בלמן, אלא לפי ערך ה- Val-loss שהתקבל.

יום Time-step

חוץ מבמקרה בו קטענו את ריצת ה-Episode משום שבכל אחד מהפעולות נגיע בהכרח למצב פחות טוב מה-Threshold אותו הגדרנו ($Q\text{-value} < -0.01$), בסיום כל Time-step נעדכן את הערכים בטבלת ה-Q ונעדכן את המצב הנוכחי כמצב הבא, כלומר המצב **לאחר ביצוע הפעולה** של בחירת פיצ'ר שלא נבחר עדיין.

לאחר מכן, נוציא את הפיצ'ר שנבחר מרשימת הפיצ'רים האפשריים לבחירה ונתחיל Time step חדש, למעט במקרה בו לא נותרו עוד פיצ'רים ולכן נסיים את האפיזודה ונתחיל חדשה (עם ערכים מאותחלים, טבלת Q מעודכנת וצ'אנק חדש של דאטה).

יום Episode

כל אפיזודה תסתיים כאשר תתמלאנה אחת משתי האפשרויות:

א. בהינתן שאנו במצב מסויים ובאפשרות ה-Actor לבחור פיצ'ר כלשהו מסט הפיצ'רים שטרם נבחר, אם כל ערך אפשרי שיתקבל מבחירת כל אחת מהפעולות האפשריות **קטן** מ- Threshold שהגדרנו (במקרה שלנו -0.1) **ובנוסף** סט הפיצ'רים אינו הקבוצה הריקה {}.

ב. כאשר מהמצב בו אנו נשארים לא ניתן לבצע פעולות נוספות. כלומר, לא נשארו עוד פיצ'רים לבחירה (פורמלית - כאשר סט הפיצ'רים האפשריים $F_{\text{available}}$ הינו סט ריק-הקבוצה הריקה {})



2. תכנות הפתרון

א. תכנות אלגוריתם RL - מצורף קובץ הקוד שלנו.

ב. תכנות הלולאה - מצורף קובץ הקוד.

ג. הרצת הלולאה על הנתונים + מסקנות:

בסיום כל 1,966 האיטרציות (כל ה-Episodes) אשר הוסברו בסעיפים קודמים קיבלנו פוליסי סופית כפי שנלמדה לכל אורך לולאת הסקרנות כמו שניתן לראות מטה-


```
The order of the feature selection by Q is:  
[4, 3, 2, 1, 9, 10, 13, 5, 12, 6, 11, 7, 8]
```

כאשר מיפוי הפיצ'רים הוא כפי שמופיע מטה (1 הפיצ'ר הכי שמאלי ו 13 הפיצ'ר הכי ימני והם מסודרים לפי הסדר המספרי שלהם)



xG	xGA	npxG	npxGA	deep	deep_allowed	npxGD	ppda_coef	ppda_att	ppda_def	oppda_coef	oppda_att	oppda_def
----	-----	------	-------	------	--------------	-------	-----------	----------	----------	------------	-----------	-----------

מדיניות זו נקבעת על ידי טבלת ה-Q הסופית שבידינו. כעת, נבחן באמצעות מודל ה-DRL, במקרה שלנו ANN, על ה-Test Dataset אותו השארנו בצד (20% מכל הרשומות). במקרה שלנו נריץ את הפוליסי הסופית לעומת בחירה רנדומית של פיצ'רים (נרצה לוודא כי המודל שברשותנו "מנצח" מודל הבוחר את הפיצ'רים שלו רנדומית).

כאמור, ניתן לראות בגרף מטה את תוצאות השגיאה על ה test set כאשר הצעדים היו לפי הפוליסי הנבחר שלנו וכאשר הצעדים נבחרו בצורה רנדומית וניתן להסיק מכך שהיתרון היחסי שלנו הוא בהתכנסות המהירה כבר באיטרציה השניה בזמן שהבחירה הרנדומית מתכנסת רק לאחר 4 איטרציות.






הדבר נכון גם לגבי ה loss ולגבי ה accuracy כמו שניתן לראות מהגרפים שמודדים זאת לאחר בחנו את ה train set עם הפוליסי שלנו אל מול צעידה אקראית-







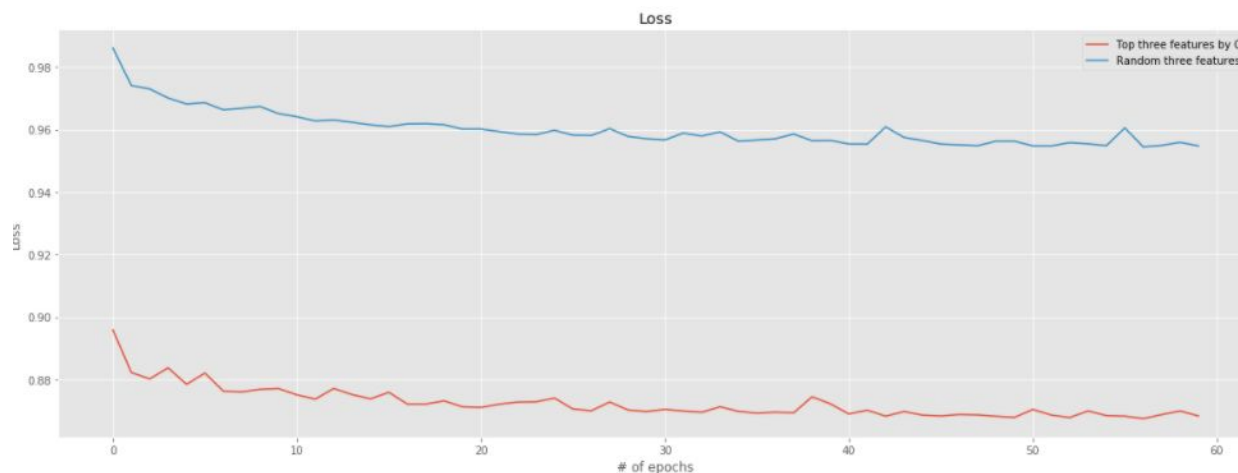
בחנו את ה error (MSE), val loss, reward, accuracy של הלמידה כדי לחפש מגמה כלשהי והתכנסות ונוכחנו לגלות שלא היתה מגמה ברורה שכזו לצערנו.

אנו סבורים שתוצאות אלו נובעות מאופי הדאטה שלנו והקורלציה של הפיצ'רים לערך המטרה, ראינו כבר מניתוח בעבודה הקודמת כי ישנם 3 פיצ'רים "חזקים" וכל שאר הפיצ'רים בעלי קורלציה די נמוכה ודי שוויונית כך שמרגע שהפיצ'רים החזקים נבחרו אין כ"כ משמעות לסדר הבחירה ולכן לא ניתן לראות מגמה מונטונית לאורך האפיזודות אך כן ניתן לראות שבאופן כללי הפוליסי שלנו הוא יותר חזק מבחירה רנדומלית וגם כי הפוליסי שלנו בוחר לנו את 3 הפיצ'רים האלו שכבר גילינו מניתוח הפיצ'רים בעבודה הקודמת ומראה לנו שהם מביאים לתוצאות משמעותיות יותר טובות מבחירת 3 פיצ'רים רנדומלית.





כאמור, נוכחנו כי לאחר שהרצנו את הקוד שלנו מספר פעמים היו 3 פיצ'רים מרכזיים שחזרו על עצמם ותמיד נבחרו ראשוני על מטרצת Q והם - xG , xGA , $qxGA$ (מדדי הגולים הצפויים/גולים צפויים כנגד וגולים צפויים בלי פנדלים ושערים עצמאיים) וכאשר הרצנו את הרשת שלנו עליהם אל מול הרצה של הרשת עם 3 פיצ'רים רנדומיים אכן ראינו loss משמעותי נמוך יותר ודיוק משמעותי גבוה יותר בהרצה עם 3 הפיצ'רים ה"חזקים" כמו שניתן לראות בגרפים מטה-






3. בונוס: מיפוי הבעיה למוח ולפסיכולוגיה

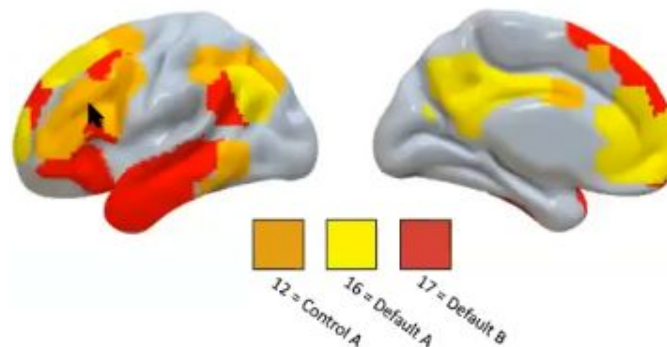
א. תיאור האיזורים המוחיים והרשת המוחית שמסוגלת לפתור את הבעיה הנ"ל.

ב. תיאור תהליכי הלימוד שיאפשרו לאדם לפתור את הבעיה הנ"ל.

א. שני האיזורים הרלוונטיים לבעיית הסקרנות שלנו, הן Nucleus Accumbens (כחלק מאיזור ה-Hippocampus) ו-Sn/VTA, כאשר האיזור הראשון רלוונטי יותר לשאלות המתוארות כ-high curiosity (כמו בנושא שלנו), ויש יותר סיכוי שיזכרו את השאלות ששאלנו את עצמנו במהלך התהליך. האיזור השני רלוונטי גם לשאלות המוגדרות כ-low curiosity ושם סיכוי פחות או יותר דומה לזכור או לשכוח את השאלות. החלק השני בעצם משדר לחלק הראשון את ה-novelty, אלמנט גירוי שהמוח שלנו חפץ בו כדי ללמוד ולספק את הגירוי. לעניין הרשת המוחית שמסוגלת לפתור את הבעיה, הרי שהיא מסובכת. קיימים בה המון איזורים שונים שאחראים לדברים שונים כגון: תפיסה ויזואלית, תשומת לב, שליטה, אינטגרציה של המידע שהתקבל וכו'. אוסף האיזורים האלה מהווים רשת שמסוגלת לפתור את הבעיה.



מבנה רשת שמופעלת בתהליכי סקרנות high level:





כאשר האיזורים הכתומים אחראיים על שליטה של מידע קוגניטיבי
האדומים - עושים decode למידע סמנטי.
הצהובים - עושה אינטגרציה בין החלקים השונים של המידע.

ב. תהליכי הלימוד שיאפשרו לאדם לפתור את הבעיה בצורה המיטבית, עפ"י מה שד"ר גרובר
אמר, הוא לשאול קודם את השאלה, אח"כ את המידע הויזואלי כמה שיותר מוקדם אחרי
השאלה וכך תהליכי הזיכרון יעבדו בצורה טובה יותר עבור תהליך של high curiosity כמו
בבעיה שלנו. יש לציין, שהלמידה תהיה אפקטיבית יותר בסביבה שיש בה יותר גירויים לסקרנות
בטבעה, גירויים שיעודדו novelty ללמידה אפקטיבית יותר, ולתהליכי זיכרון טובים יותר.



נספחים:

א. תיאור הפיצ'רים:

פיצ'ר	תיאור	תחום ערכים
xG	מטריקה לגולים צפויים שהקבוצה תכבוש במשחק, כימות סטטיסטי בין מספר מצבי ההבקעה שמוערך שתממש (כלומר יבשילו לכיבוש) לעומת כלל מצבי ההבקעה המשוערים של הקבוצה	0-6.63 תחום רציף
xGA	מטריקה לגולים צפויים שהקבוצה תספוג במשחק, כימות סטטיסטי בין ממוצע מצבי ההבקעה של יריבותיה = מימוש לעומת כלל מצבי ההבקעה של יריבותיה	0-6.63 תחום רציף
npvG	גולים צפויים שהקבוצה תכבוש במשחק, לא כולל פנדלים ושערים עצמיים	0-6.61 תחום רציף
npvGA	צפי לספיגה לקבוצה במשחק, לא כולל פנדלים ושערים עצמיים	0-6.61 תחום רציף
npvGD	הפרש בין צפי להבקעות לעומת ספיגות, לא כולל פנדלים ושערים עצמיים	6 - (-6) תחום רציף
ppda_att	מספר המסירות ההתקפיות המוצלחות* שנעשו ע"י הקבוצה	0-764 תחום בדיד
ppda_def	מספר המסירות ההגנתיות המוצלחות (בין שחקני ההגנה או מסירות אחורה) שנעשו ע"י הקבוצה	0-65 תחום בדיד
oppda_att	מספר המסירות ההתקפיות המוצלחות* שנעשו ע"י הקבוצה היריבה	0-764 תחום בדיד
oppda_def	מספר המסירות ההגנתיות המוצלחות* שנעשו ע"י הקבוצה היריבה	0-65 תחום בדיד
ppda_coef	עוצמת הלחץ שהקבוצה מפעילה בחצי המגרש של היריבה. כלומר, היחס בין מס' המסירות המוצלחות* שהיא מבצעת בחצי המגרש של היריבה לבין מס' הפעולות ההגנתיות של היריבה - חילוך, פאול, חטיפת הכדור וכו'	0-152 תחום רציף
oppda_coef	עוצמת הלחץ שהקבוצה היריבה מפעילה בחצי המגרש של הקבוצה השניה. כלומר, היחס בין מס' המסירות המוצלחות* שהיריבה מבצעת בחצי המגרש של הקבוצה השניה לבין מס' הפעולות ההגנתיות של הקבוצה השניה	0-152 תחום רציף
deep	מסירות מוצלחות* שהושלמו במרחק של פחות מ-18 מטר משער היריבה (מסירות בתוך רחבת שער היריבה)	0-42 תחום בדיד
deep_allowed	מסירות מוצלחות* שהיריבה השלימה במרחק של פחות מ-18 מטר משער הקבוצה השניה	0-42 תחום בדיד

*מסירה מוצלחת - מוגדרת כמוצלחת כאשר הכדור הועבר בין שני שחקנים באותה הקבוצה, ללא קטיעה (חטיפה ע"י שחקן יריב, עבירה שבגינה המשחק הופסק, נבדל או שהכדור יצא מתחומי המגרש)



פיצ'רים בהם בחרנו שלא להשתמש (הורדנו בתהליך "ניקוי" הדאטה):

פיצ'ר	תיאור	תחום ערכים	סיבת הניפוי
xpts	נקודות צפויות לקבוצה, למשחק	0-3 תחום רציף	מגלה למודל בהסתברות גבוהה מדי (> 90% מהמקרים) מה תהיה התוצאה בפועל. החלטנו כי הדבר פוגע בלמידה
xG_diff	ההפרש בין גולים שהובקעו בפועל ומספר הגולים הצפוי, לקבוצה	5.9 - (-5.9) תחום רציף	הסיבה שבחרנו להוריד את הפיצ'רים האלה היא משום שהם "מגלים" למודל מה התרחש בהסתברות = 1 (לפי ההפרשים ניתן לדעת בדיוק מה קרה במשחק- ניסינו וזה נתן לנו מההתחלה val_acc=1
xGA_diff	ההפרש בין הגולים שהקבוצה ספגה בפועל במשחק לעומת הצפי לספיגה של הקבוצה במשחק	5.9 - (-5.9) תחום רציף	
Xpts_diff	ההפרש בין הנקודות שקיבלה הקבוצה בפועל ומספר הנקודות הצפוי שתקבל	2.9 - (-2.9) תחום רציף	
Scored	כמה הקבוצה הבקיעה	0-10 תחום בדיד	הסיבה שבחרנו להוריד את הפיצ'רים האלה היא משום שהם "מגלים" למודל מה התרחש בהסתברות = 1
missed	כמה הקבוצה היריבה הבקיעה	0-10 תחום בדיד	
result	התוצאה הסופית-האם הקבוצה ניצחה או הפסידה	{W,D,L} קטגוריאלי	
wins	האם בפועל הקבוצה ניצחה?	{0,1} תחום בינארי	
draws	האם בפועל הקבוצה סיימה בתיקו?	{0,1} תחום בינארי	
loses	האם בפועל הקבוצה הפסידה?	{0,1} תחום בינארי	
Year	שנת המשחק הספציפי (שנת תיעוד השורה בדאטה)	2014-2019 תחום בדיד	לא רלוונטי לעולם אותו אנו חוקרים
League	שם הליגה בה המשחק התרחש	{בונדסליגה (גרמניה), פרמיירליג (אנגליה), לה-ליגה (ספרד), סרייה-א (איטליה), ליגה 1 (צרפת), ארפיאל (רוסיה)} קטגוריאלי	משום שבעולם הנחקר קבוצות יתחרו תמיד מול קבוצות באותה הליגה- להערכתנו, לא רלוונטי לעולם הספציפי אותו אנו חוקרים
h_a	Home_Away - האם הקבוצה מארחת בביתה או מתארחת	בית או חוץ קטגוריאלי	לא רלוונטי לעולם אותו אנו חוקרים
team	שם הקבוצה	קטגוריאלי	לא רלוונטי לעולם אותו אנו חוקרים